Министерство науки и высшего образования Российской Федерации
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО

Факультет Прикладной информатики

О Т Ч Е Т

По лабораторной работе №1
По дисциплине Современные методы искусственного интеллекта

Тема работы Классификация изображений с применением Transfer Learning
Факультет Прикладной информатики
Группа К3320
Направление подготовки 11.03.02 Инфокоммуникационные технологии и системы связи
Образовательная программа Программирование в инфокоммуникационных системах

Обучающийся _____ _____ Лоскутов А.В.
(дата) (подпись) (Ф.И.О.)

Руководитель _____ _____ Царёв Д.В.
(дата) (подпись) (Ф.И.О.)

Санкт-Петербург
2026

СОДЕРЖАНИЕ

ВВЕДЕНИЕ.....3
1. ПРЕДВАРИТЕЛЬНАЯ ОБРАБОТКА ДАННЫХ.....4
1.1 Бинаризация.....4
1.2 Исключение среднего.....4
1.3 Масштабирование.....4
1.4 Нормализация.....5
2. КОДИРОВАНИЕ МЕТОК.....6
3. ЛОГИСТИЧЕСКИЙ КЛАССИФИКАТОР.....7
4. НАИВНЫЙ БАЙЕСОВСКИЙ КЛАССИФИКАТОР.....9
5. МАТРИЦА НЕТОЧНОСТЕЙ.....11
6. МАШИНЫ ОПОРНЫХ ВЕКТОРОВ.....13
7. РЕГРЕССИЯ.....15
7.1 Регрессия одной переменной.....15
7.2 Многомерный регрессор.....16
8. ОЦЕНКА СТОИМОСТИ НЕДВИЖИМОСТИ.....17
9. ОБУЧЕНИЕ МОДЕЛИ.....19
ВЫВОД.....21

ВВЕДЕНИЕ

Репозиторий: https://github.com/ArtemLoskutow/ModernAIM

Цель: получить практические навыки по обучению распознавания образов, кластеризации и классификации данных с помощью обучения с учителем и метода transfer learning.

Ход работы:

1. Выполнить предварительную обработку данных с использованием методов бинаризации, исключения среднего, масштабирования и нормализации;
2. Изучить кодирование категориальных меток и обратное преобразование числовых значений в исходные метки;
3. Исследовать работу логистического классификатора и влияние параметра C на результат классификации;
4. Исследовать работу наивного байесовского классификатора и оценить качество классификации;
5. Построить матрицу неточностей и рассчитать основные метрики качества классификации;
6. Исследовать машину опорных векторов с различными ядрами и параметрами и сравнить полученные результаты;
7. Исследовать линейную и многомерную регрессию и оценить качество построенных регрессионных моделей;
8. Исследовать применение методов машинного обучения для оценки стоимости недвижимости и сравнить результаты различных вариантов модели.

1. ПРЕДВАРИТЕЛЬНАЯ ОБРАБОТКА ДАННЫХ

Для классификации данных недостаточно просто иметь сами данные. Необходимо их обработать, чтобы алгоритм по результатам мог выявлять категории и классифицировать новые объекты.

Для работы дана матрица:

5.1 -2.9 3.3

-1.2 7.8 -6.1

3.9 0.4 2.1

7.3 -9.9 -4.5

1.1 Бинаризация

Её можно привести к значениям 1 и 0 при помощи бинаризации и опорного значения (для примера 2.1):

1 0 1

0 1 0

1 0 0

1 0 0

1.2 Исключение среднего

Можно центрировать значения относительно нуля с помощью метода исключения среднего (среднее значение по каждому столбцу становится близким к нулю, а стандартное отклонение - равным единице):

0.43 -0.28 1.13

-1.59 1.41 -1.18

0.04 0.24 0.84

1.13 -1.37 -0.79

1.3 Масштабирование

Также возможно принять максимальное значение за 1 и привести все значения в диапазон от 0 до 1 с помощью масштабирования:

0.74 0.40 1

0 1 0

0.6 0.58 0.87

1 0 0.17

1.4 Нормализация

Наконец можно преобразовать значения в рядах так, чтобы в сумме по модулю или в сумме квадратов под корнем они были равны 1. Это достигается с помощью нормализации:

L1 нормализация:

0.45 -0.26 0.29

-0.08 0.52 -0.40

0.61 0.06 0.33

0.34 -0.46 -0.21

L2 нормализация:

0.76 -0.43 0.49

-0.12 0.78 -0.61

0.88 0.09 0.47

0.56 -0.76 -0.34

2. КОДИРОВАНИЕ МЕТОК

Кодирование меток преобразует текстовые значения в числовые, с которыми могут работать алгоритмы машинного обучения. Обратное преобразование позволяет получить исходные текстовые метки.

Работа алгоритма:

```
Label mapping:
black --> 0
green --> 1
red --> 2
white --> 3
yellow --> 4

Labels = ['green', 'red', 'black']
Encoded values = [np.int64(1), np.int64(2), np.int64(0)]

Encoded values = [3, 0, 4, 1]
Decoded labels = [np.str_('white'), np.str_('black'), np.str_('yellow'),
np.str_('green')]
```

3. ЛОГИСТИЧЕСКИЙ КЛАССИФИКАТОР

Чтобы выявить закономерность между входными (независимыми) и выходными (зависимыми) данными используется логистический классификатор. По обучающим данным алгоритм понимает как ему классифицировать новые объекты, а показатель C показывает как сильно алгоритм стремится избежать ошибок классификации.

Для работы были даны обучающие входные данные: [3.1, 7.2], [4, 6.7], [2.9, 8], [5.1, 4.5], [6, 5], [5.6, 5], [3.3, 0.4], [3.9, 0.9], [2.8, 1], [0.5, 3.4], [1, 4], [0.6, 4.9], а также выходные данные: [0, 0, 0, 1, 1, 1, 2, 2, 2, 3, 3, 3]. По данным была построена визуализация классификации новых объектов в зависимости от входных данных (местоположения в координатах в данной работе). На рисунках 1 и 2 представлены визуализации с параметром C = 1 и C = 100 соответственно:

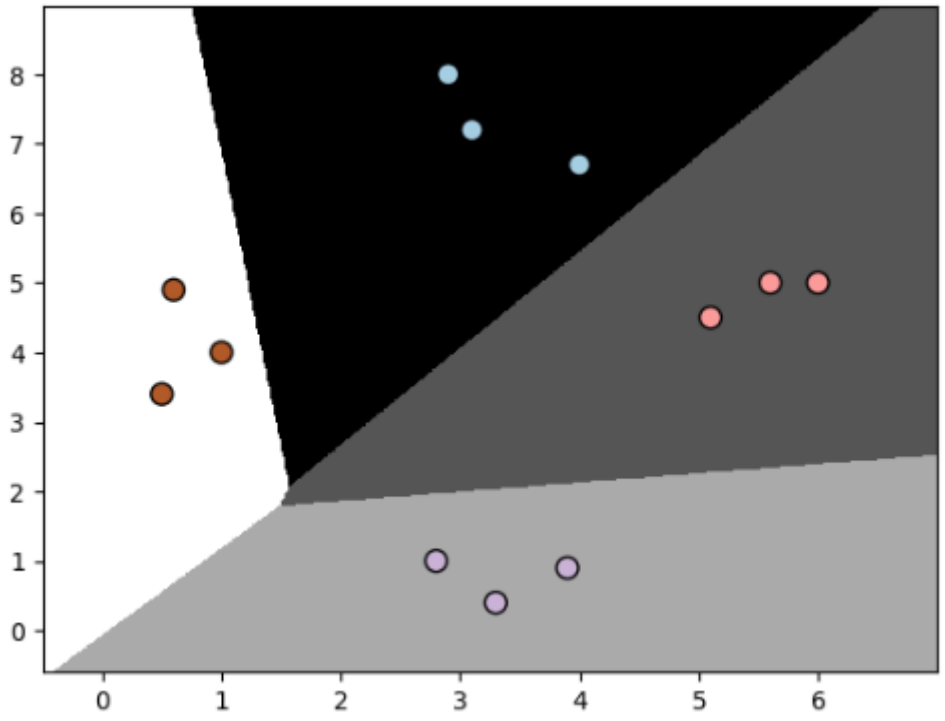


Рисунок 1 - Параметр C = 1

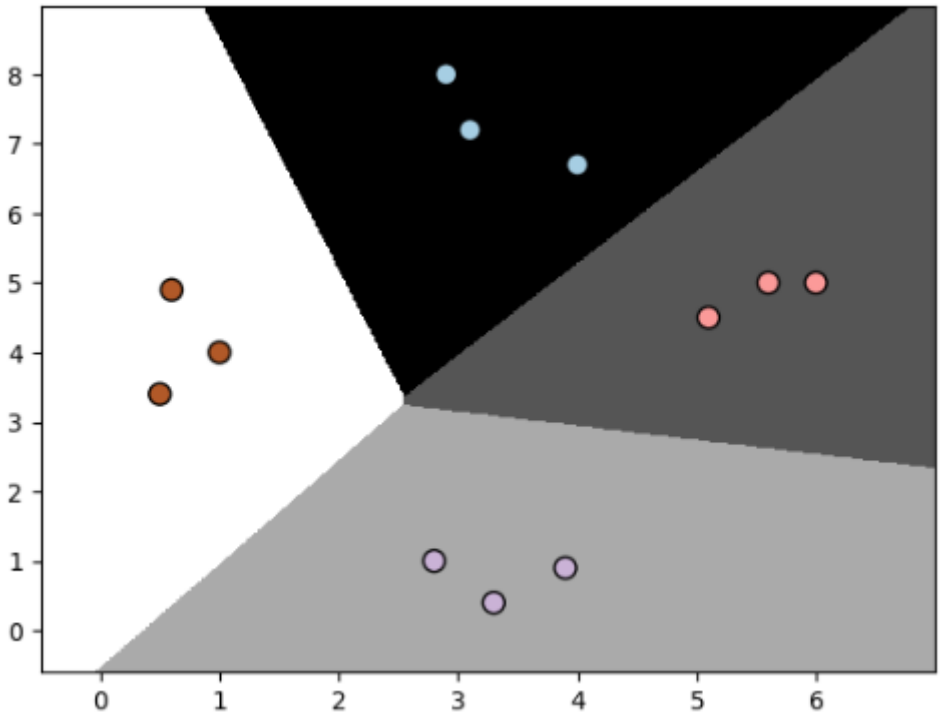


Рисунок 2 - Параметр C = 100

Видно, как при увеличении параметра C алгоритм стал сильнее подстраиваться под обучающие данные и точка пересечения зон классификации в работе сместилась ближе к центру, в отличии от C = 1.

4. НАИВНЫЙ БАЙЕСОВСКИЙ КЛАССИФИКАТОР

Принимая набор признаков и классов по признакам алгоритм, считая признаки независимыми, находит вероятность присвоения по признакам определённого класса.

В работе дан массив значений, приложенный в репозитории. Первоначально предлагается обучить и протестировать алгоритм на одних и тех-же данных. Результат показал точность 99.75%. Рисунок 3 представляет визуализацию распределения и классификации данных.

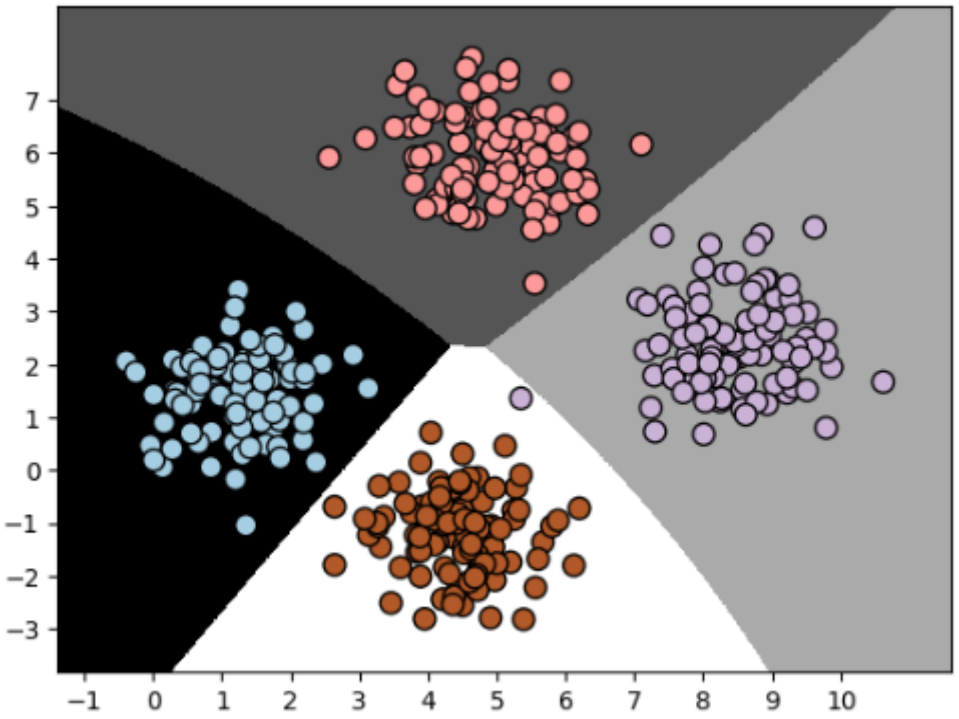


Рисунок 3 - Визуализация данных

Для более точной классификации требуется разделить набор признаков и классов на обучающий и тестовый наборы. Проведя обучение на 80% исходных данных и протестировав на оставшихся 20% классификатор показал 100% точность. На рисунке 4 представлена визуализация тестовых данных и их классификации, на основе обучающих данных.

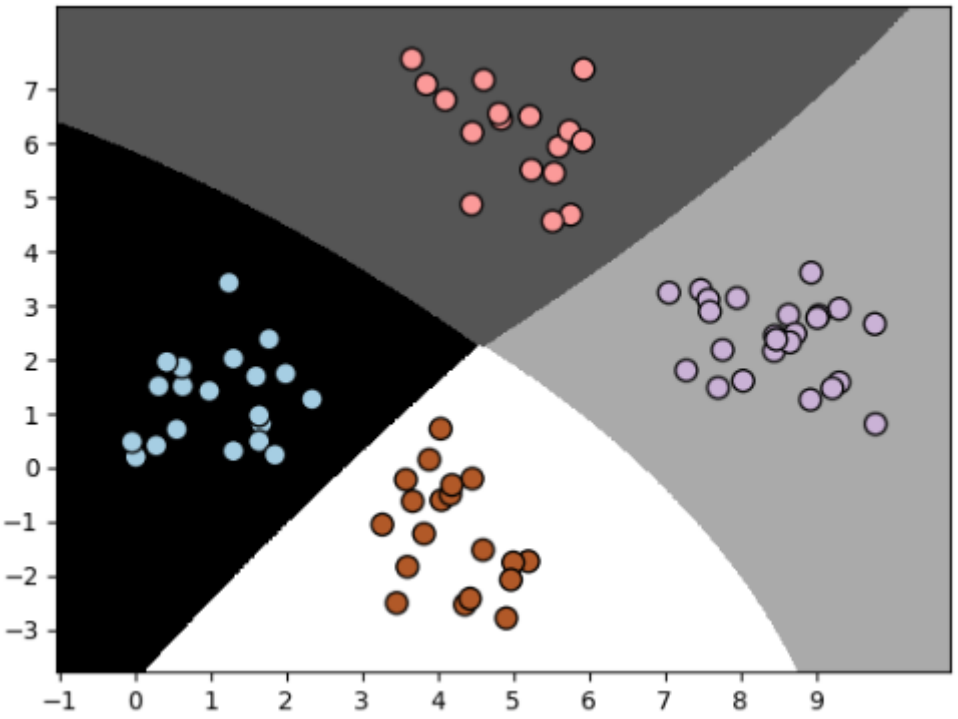


Рисунок 4 - Визуализация тестовых данных

На основании тройной перекрёстной проверки были получены следующие метрики: Accuracy: 99.75%, Precision: 99.76%, Recall: 99.75%, F1: 99.75%.

5. МАТРИЦА НЕТОЧНОСТЕЙ

Для описания точности классификатора используется матрица неточностей, содержащая информацию о верно определённых ложных и истинных значениях, а также неверно определённых ложных и истинных значениях.

Для работы даны истинные значения: [2, 0, 0, 2, 4, 4, 1, 0, 3, 3, 3] и предсказанные значения: [2, 1, 0, 2, 4, 3, 1, 0, 1, 3, 3]. По этим данным строится матрица неточностей, представленная на рисунке 5, где строки обозначают истинные значения, а столбцы предсказанные.

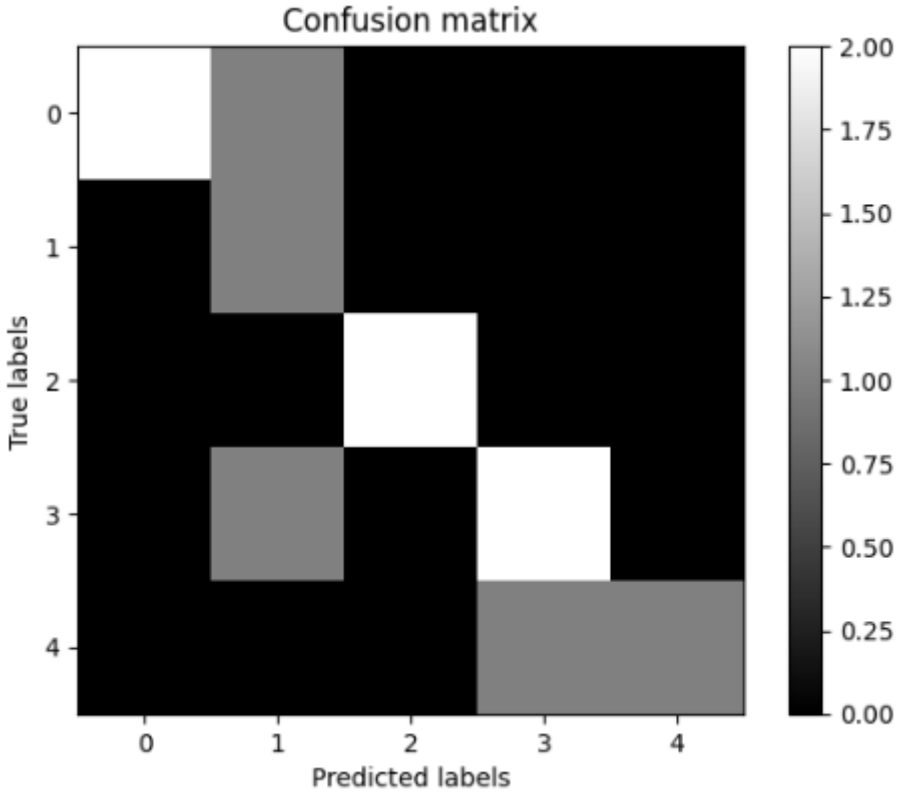


Рисунок 5 - Матрица неточностей

Дополнительно были получены показатели:

	precision	recall	f1-score	support
Class-0	1.00	0.67	0.80	3
Class-1	0.33	1.00	0.50	1
Class-2	1.00	1.00	1.00	2
Class-3	0.67	0.67	0.67	3
Class-4	1.00	0.50	0.67	2

accuracy			0.73	11
macro avg	0.80	0.77	0.73	11
weighted avg	0.85	0.73	0.75	11

В результате классификации правильными оказались 8 из 11 объектов, что соответствует Accuracy = 0.73. Лучше всего был распознан класс 2: для него Precision, Recall и F1-score равны 1.00. Для класса 1 Recall равен 1.00, однако Precision составляет только 0.33, поскольку два объекта других классов были ошибочно отнесены к классу 1. Для класса 4 Recall составляет 0.50, так как один из двух объектов этого класса был отнесён к классу 3. В целом классификатор правильно определил большинство объектов.

6. МАШИНЫ ОПОРНЫХ ВЕКТОРОВ

Для машины опорных векторов используется разделение значений гиперплоскостями так, чтобы между опорными векторами было максимальное расстояние.

Файл с обучающими данными находится в репозитории. Предлагается рассмотреть SVM на разных ядрах и с разным параметром C. В качестве обучающего набора использовался файл с данными о людях, содержащий как числовые, так и категориальные признаки. Для работы с категориальными признаками их значения предварительно были преобразованы в числовой вид

Были использованы: linear, rbf, poly. Для тестирования были выбраны наборы:

['37', 'Private', '215646', 'HS-grad', '9', 'Never-married', 'Handlers-cleaners', 'Not-in-family', 'White', 'Male', '0', '0', '40', 'United-States'],

['52', 'Self-emp-not-inc', '209642', 'HS-grad', '9', 'Married-civ-spouse', 'Exec-managerial', 'Husband', 'White', 'Male', '0', '0', '45', 'United-States'],

['29', 'Private', '190000', 'Bachelors', '13', 'Never-married', 'Prof-specialty', 'Not-in-family', 'White', 'Female', '0', '0', '40', 'United-States'].

Результат работы алгоритма:

```
Kernel: linear C: 1
F1 score: 77.55 %
Precision: 77.57 %
Recall: 77.55 %
Точка 1: <=50K
Точка 2: >50K
Точка 3: <=50K

Kernel: linear C: 10
F1 score: 77.4 %
Precision: 77.42 %
Recall: 77.4 %
Точка 1: <=50K
Точка 2: >50K
Точка 3: <=50K

Kernel: rbf C: 1
F1 score: 81.25 %
Precision: 81.85 %
Recall: 81.3 %
```

```
Точка 1: <=50K
Точка 2: >50K
Точка 3: <=50K

Kernel: poly C: 1
F1 score: 77.74 %
Precision: 79.77 %
Recall: 78.0 %
Точка 1: >50K
Точка 2: >50K
Точка 3: <=50K
```

Наилучшие результаты показало ядро rbf с параметром c = 1. Изменение параметра c до 10 не дало ощутимого прироста точности. Была также выявлена зависимость результата от выбора ядра: poly для первой точки спрогнозировало результат больше 50 тысяч, тогда как остальные ядра прогнозировали меньше 50 тысяч.

7. РЕГРЕССИЯ

Регрессия применяется для прогнозирования числового значения на основе одного или нескольких входных признаков. В отличие от задачи классификации, результатом регрессии является конкретное числовое значение, а не принадлежность объекта к определённому классу.

В работе были рассмотрены регрессия одной переменной и многомерная регрессия.

7.1 Регрессия одной переменной

Из файла data_singlevar_regr.txt, приложенного в репозитории, берутся числовые признаки. Средняя ошибка составила всего 0.59 единиц, а сам регрессор смог объяснить 86% изменчивости переменной.

Linear regressor performance:
Mean absolute error = 0.59
Mean squared error = 0.49
Median absolute error = 0.51
Explain variance score = 0.86
R2 score = 0.86

Для дополнительной проверки модели была рассчитана средняя абсолютная ошибка на новом наборе данных. Полученное значение составило 0.59, что совпало с ранее полученным MAE.

New mean absolute error = 0.59

На рисунке 6 представлена линейная регрессия построенная по всем входящим значениям и выходящим результатам.

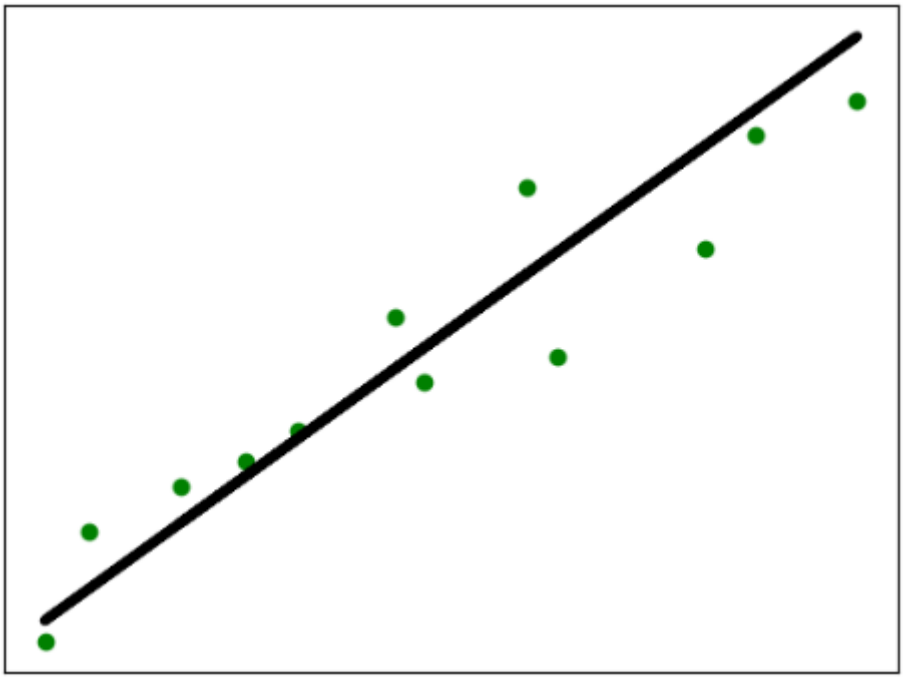


Рисунок 6 - Линейная регрессия

7.2 Многомерный регрессор

Для многомерного регрессора используется файл data_multivar_regr.txt с четырьмя входными переменными. Оценка регрессора дала результат:

```
Linear Regressor performance:
Mean absolute error = 3.58
Mean squared error = 20.31
Median absolute error = 2.99
Explained variance score = 0.86
R2 score = 0.86
```

Кроме того, были получены прогнозы с использованием линейной и полиномиальной регрессии. Линейная регрессия дала прогноз 36.05, тогда как полиномиальная регрессия дала значение 41.08. Полиномиальная модель лучше учитывает нелинейные зависимости между признаками, поэтому её прогноз в данном случае отличается от линейного. Рассматриваемая тестовая точка близка к точке с известным результатом около 41.35, поэтому прогноз полиномиальной модели оказался ближе к ожидаемому значению.

```
Linear regression:
 [36.05286276]
Polynomial regression:
 [41.08312885]
```

8. ОЦЕНКА СТОИМОСТИ НЕДВИЖИМОСТИ

В данном разделе рассматривается применение методов машинного обучения для прогнозирования стоимости недвижимости. Качество полученных моделей оценивается с использованием среднеквадратичной ошибки и показателя объяснённой дисперсии.

В работе было изучено влияние параметров C и эпсилон на прогнозирование цены. Значения составили: [C = 1.0; eps = 0.1], [C = 0.1; eps = 0.01], [C = 10.0; eps = 0.5]. Для теста были рассмотрены следующие параметры квартир:

[3.7, 0, 18.4, 1, 0.87, 5.95, 91, 2.5052, 26, 666, 20.2, 351.34, 15.27];

[4.3, 21, 12, 33, 42, 52, 67, 0.8, 0.01, 5.0001, 2, 1, 7];

[7.62, 5.56, 4, 16, 50, 77, 92, 0.1, 9, 100, 65, 56, 13].

Вывод алгоритма представлен ниже.

```
#### Performance ####
Mean squared error = 15.38
Explained variance score = 0.82

Predicted price: 18.521780107258536
Predicted price: 253.63262296730406
Predicted price: 302.62763761384207


#### Performance ####
Mean squared error = 16.99
Explained variance score = 0.8

Predicted price: 18.841144346432024
Predicted price: 183.66931400578568
Predicted price: 200.62886865726892


#### Performance ####
Mean squared error = 15.07
Explained variance score = 0.82

Predicted price: 17.67201082954412
Predicted price: 31.507093749346637
Predicted price: 36.73129917063048
```

Наименьшее значение MSE было получено при C = 10 и eps = 0.5, поэтому данный вариант показал наилучший результат по данной метрике.

Значение объяснённой дисперсии для него составило 0.82, что также соответствует лучшему значению среди рассмотренных моделей. Изменение параметра C оказало сильное влияние на прогнозирование цены, сравнивая полученные значения на вторую и третью квартиры.

9. ОБУЧЕНИЕ МОДЕЛИ

В работе был использован датасет vggflowers. Для классификации 102 видов цветов была выбрана MobileNetV3-Small за относительно небольшие вычислительне затраты.

Feature Extraction (обучение классификатора). Были заморожены все основные параметры модели. Изменялся только классификатор для 102 классов. Результатом обучения классификатора стали результаты:

```
Accuracy: 70.22%
Precision: 78.74%
Recall: 70.22%
```

Также была построена матрица ошибок классификатора, представленная на рисунке 7.

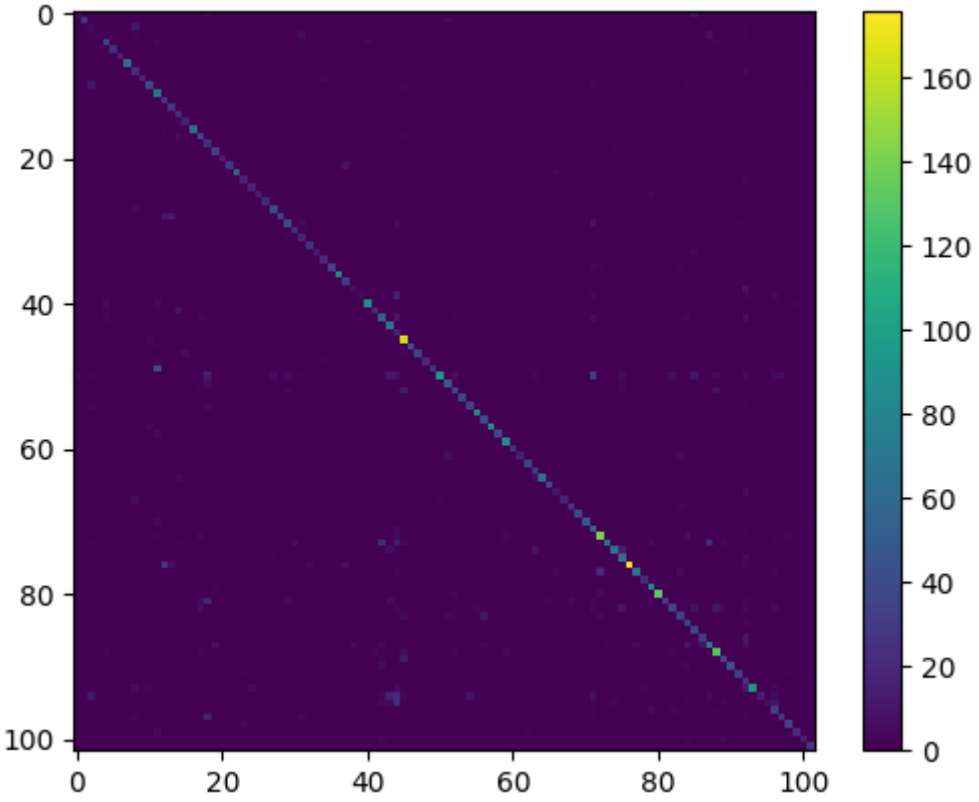


Рисунок 7 - Матрица ошибок Feature Extraction

Fine-tuning (дореобучение весов и классификатора). В отличии от Feature Extraction были размерожены и дообучены последние слои модели, что повысило точность классификатора для выбранного датасета, но потребовало больше ресурсов для обучения.

```
Accuracy: 76.21%
Precision: 79.91%
Recall: 76.21%
```

Как показали два обучения модели - Accuracy и Recall совпали внутри каждого обучения. Дообучение весов Fine-tuning повысило точность классификации изображений для выбранного датасета. Таким образом переобучение весов по стратегии Fine-tuning стоит выбирать, если допустимо сравнительно среднее ожидание расчётов модели, тогда как стратегия Feature Extraction предпочтительная для меньших вычислений, но с понижением точности классификатора.

ВЫВОД

В ходе лабораторной работы были изучены основные методы машинного обучения: классификация, регрессия и предварительная обработка данных.

При работе с методом опорных векторов было проверено влияние разных ядер и параметра C на результат классификации. Лучший результат показало ядро RBF при C = 1.

При работе с регрессией были рассчитаны основные показатели модели. Средняя абсолютная ошибка составила 0.59, а коэффициент изменчивости - 0.86. Для многомерной регрессии были сравнены линейная и полиномиальная модели.

Также была рассмотрена оценка стоимости недвижимости с помощью метода опорных векторов. Было проверено несколько вариантов параметров C и эпсилон. Лучший результат по среднеквадратичной ошибке получен при C = 10 и эпсилон = 0.5.

В дополнительном задании была рассмотрена классификация 102 видов цветоа с использованием предобученной модели MobileNetV3-Small. В обучении использовались две стратегии: Feature Extraction (заморозка модели, кроме выходного классификатора) и Fine-tuning (разморозка последних слоёв модели для дообучения). Fine-tuning показал лучший результат в сравнении с Feature Extraction (Accuracy: 70.22% повысилось до Accuracy: 76.21%, а Precision: 78.74% повысилось до Precision: 79.91%), но и потребовал больше вычислений.

В результате работы были получены практические навыки подготовки данных, обучения моделей и оценки их результатов.